上海交通大学
SHANGHAI JIAO TONG UNIVERSITY

SJTU

LLM大作业介绍

李毅恒

2026.10.13

任务概述

本次大作业要求你**从零搭建并训练**一个小型大语言模型，参数量约 **50M–120M**，使其能够在 TinyStories 数据集上生成语法正确、语义连贯的英文短篇故事。

本次作业不限制你使用任何 PyTorch API。你可以使用 `torch.nn.Linear` 、 `nn.Embedding` 、 `nn.LayerNorm` 、 `nn.MultiheadAttention` 等任何你熟悉的模块，也可以用 `nn.Parameter` 从零手写。我们只要求你：

1. 完整理解并实现LLM的核心结构；
2. 跑通完整的训练流程（数据处理 → 模型 → 训练 → 生成）；
3. 训练出一个能在固定测试集上取得合理指标的模型；
4. 提交可复现的源码、模型检查点和一份分析报告。

我们提供了一份**框架模板** `model_template.py` ，模板提供了一个 GPT-2 风格的 decoder-only Transformer 语言模型框架，其中只包含必要的类名和函数名，函数体用伪代码提示，你需要自己补全。

数据集

TinyStories（https://huggingface.co/datasets/roneneldan/TinyStories）

- 规模：约 211 万条英文短篇故事
- 特点：词汇简单、语法基础，专为小模型语言学习设计
- 训练集：`data/TinyStories-train.txt`（约 1.9 GB）
- 验证/测试：由助教提供固定测试集（不公开，评测时使用，数据集中的`TinyStories-valid.txt`可用于自行验证，但不作为最终评测标准）

注意事项：

- 训练集和测试集不同源。评测集为助教私有，学生无法获取，也无法用于训练。
- 你可以使用完整训练集或自行取子集，但需在报告中说明。
- 取用的数据集大小和训练轮次会影响训练用时，为避免训练用时过长，进行完整的训练前需要估计好时间。（以下信息供参考：使用5070Ti laptap和800000条数据训练一个epoch大约需要3小时，在TinyStories-valid上的loss为1.6左右，BPB为0.56左右）

技术规格

需要实现的组件

- **BPE 分词器**的训练与编码
- **因果自注意力**（`CausalSelfAttention`），必须自己处理因果掩码
- **多头注意力**（`MultiHeadAttention`），多头拼接和输出投影
- **前馈网络**（`FeedForward`），建议 GELU
- **Transformer Block**（`Block`），pre-norm 结构：`x = x + attn(ln(x))`，`x = x + ffn(ln(x))`
- **GPT 主类**（`GPT`），token embedding + position embedding + blocks + ln_final + lm_head
- **训练循环**（`train`），前向、反向、优化器更新
- **评估函数**（`evaluate`），在验证集上计算 loss 和 BPB
- **生成函数**（`generate`），greedy decoding

固定随机种子

你的代码中必须包含以下种子设置：

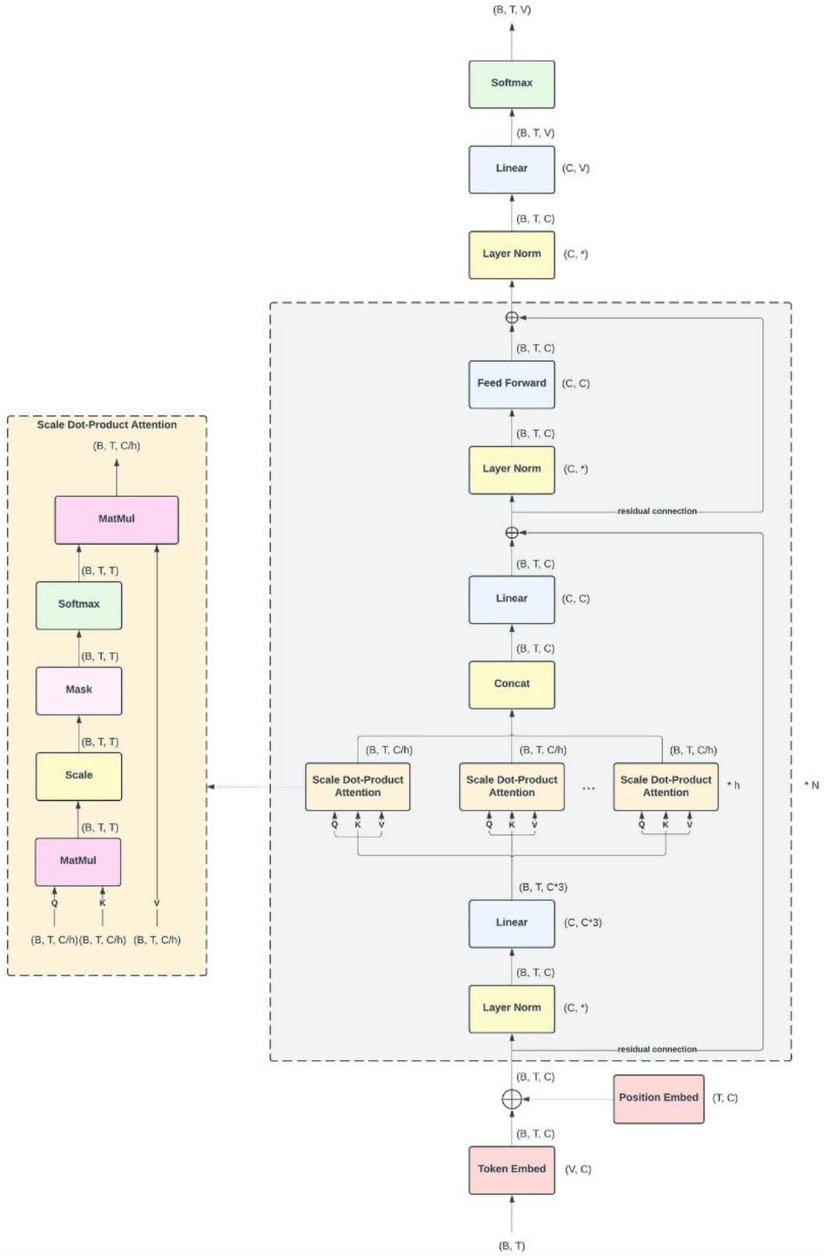
```python
import random, numpy as np, torch
random.seed(42)
np.random.seed(42)
torch.manual_seed(42)
torch.cuda.manual_seed_all(42)
torch.backends.cudnn.deterministic = True
torch.backends.cudnn.benchmark = False
```

技术规格

推荐配置（也是我们提供的模板配置）：

超参数	推荐值	说明
`block_size`	512	最大上下文长度
`n_layer`	6	Transformer 层数
`n_head`	12	注意力头数
`n_embd`	768	嵌入维度
`vocab_size`	由你的 BPE 分词器决定	建议 8192–50257
参数量	~120M	在上述配置下约为 120M

你可以调整上述超参数，但需保证参数量在 **50M–150M** 之间，并在报告中说明调整理由。



提交材料

每位同学需要提交一个压缩包：

```
学号.tar.gz
```

例如学号是 `524030912345`，则文件名是 `524030912345.tar.gz`。

压缩包内部的文件名必须统一为英文，方便助教批量评测。请严格按下面的目录结构组织：

```
学号/                    ← 压缩包解压后的顶层目录（用你的学号命名）
├── model.py             ← 模型定义，必须暴露 GPT 类
├── config.json          ← 模型配置
├── tokenizer.json       ← 你自己训练的 BPE 分词器
├── best.pt              ← 最佳模型检查点
└── report.pdf           ← 分析报告
```

不要在压缩包里放数据集（如 `TinyStories-train.txt`），也不要放 `__pycache__`、`.DS_Store`、`.ipynb_checkpoints` 等临时文件。

文件	内容	说明
`model.py`	模型定义，必须暴露 `GPT` 类	评测脚本动态导入
`config.json`	模型配置，字段与 `GPT.__init__` 的参数一致	评测脚本用它构造模型
`tokenizer.json`	你自己训练的 BPE 分词器	评测脚本用它编码评测集
`best.pt`	最佳验证 loss 的模型权重	评测脚本加载它
`report.pdf`	分析报告	人工评分

评测脚本 `eval_bpb.py` 将随本作业一同公开，你们可以自己先跑一遍，确认提交的文件能被正确加载。

自测命令：

```
python eval_bpb.py \
    --checkpoint 524030912345/best.pt \
    --config     524030912345/config.json \
    --tokenizer  524030912345/tokenizer.json \
    --model_file 524030912345/model.py \
    --eval_data  data/TinyStories-valid.txt \
    --output     results/524030912345.json
```

只要你的文件在本地能跑通，评测时也能跑通。 如果本地跑不通，评测时一定跑不通。

评测脚本会做以下几件事：

1. 从 `model.py` 动态导入 `GPT` 类；
2. 从 `config.json` 读取配置，构造模型；
3. 从 `best.pt` 加载权重；
4. 从 `tokenizer.json` 加载分词器；
5. 在助教私有评测集上计算 loss 和 BPB。

缺少上述任一文件，或文件格式不正确，评测将无法进行。

评分标准

本次大作业总分 100 分，报告 60 分 + 源码 20 分 + 评测结果 20 分，最后会以相应比例折算到总分中。

本次作业评测使用测试集上的 BPB 作为评测指标。

Bits Per Byte (BPB)：

```
BPB = (验证集上的平均交叉熵损失 × token 数) / (原始文本 UTF-8 字节数 × ln 2)
```

BPB 越低越好，且与分词器无关，可以公平比较。

助教会使用统一的评测脚本，在固定测试集上计算你的 BPB，你无法修改评测过程。

请大家尽早开始完成大作业，以免后期遇到问题来不及解决。

如遇到难以解决的问题，大家可以在课程微信群中讨论，互帮互助，也可以联系负责本次大作业的助教。

助教-黄恺奕 微信：MorphUES000 邮箱：sjtu5292760@sjtu.edu.cn

助教-李毅恒 微信：13671933226 邮箱：liyiheng@sjtu.edu.cn



上海交通大學
SHANGHAI JIAO TONG UNIVERSITY

谢　谢！